Curso
Aprendizaje Automático (ML)
con Python

Nelson López Centeno

Exploración y preparación de datos

- ❑ Análisis Exploratorio de Datos (EDA)
- ❑ Preparación de datos
  - ❑ Valores faltantes
  - ❑ Conversión de variables discretas
  - ❑ Escalado

Demos / Ejercicios

- ❑ Datasets
  - ❑ Titanic
  - ❑ Car Features and MSRP
  - ❑ California Housing Prices (1990)
- ❑ Librerias
  - ❑ Pandas
  - ❑ scikit-learn
  - ❑ DataPrep
  - ❑ YData Profiling

Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos (EDA) es utilizado por los científicos de datos para analizar e investigar conjuntos de datos y resumir sus principales características, a menudo utilizando métodos de visualización de datos.

Proporciona una mejor comprensión de las variables del conjunto de datos y las relaciones entre ellas.

Puede ayudar a determinar si las técnicas estadísticas que se están considerando para el análisis de datos son apropiadas.

Análisis Exploratorio de Datos (EDA)

Tipos de EDA

Univariable

- no gráfico: estadística descriptiva
- gráfico: histogramas, box plots

Multivariable

- no gráfico: matriz de correlación
- gráfico: scatter plot, heat map

Preparación de datos

Valores faltantes

- Eliminar filas o columnas
- **Imputación**
  - Valor constante
  - Media
  - Mediana
  - Moda
  - Multivariable

Preparación de datos

Conversión de variables discretas

- Codificar el texto como valores numéricos
- Dummies (One-hot encoding)

ocean_proximidity
1 H OCEAN
INLAND
NEAR OCEAN
ISLAND

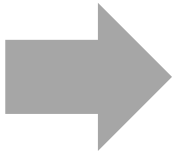

1 H OCEAN	INLAND	NEAR OCEAN	ISLAND
1	0	0	0
0	1	0	0
0	0	1	0
0	0	0	1

Preparación de datos

Escalado

La mayoría de los algoritmos de ML no funcionan bien si las diferentes características tienen diferentes escalas.

- Min-max (normalización)
- Estandarización

EDA con YData Profiling

Titanic
Car Features and MSRP
California Housing Prices (1990)

EDA con DataPrep

Titanic
Car Features and MSRP
California Housing Prices (1990)

Preparación de datos

Valores faltantes con Pandas

Preparación de datos

Valores faltantes con scikit-learn

Preparación de datos

Limpieza de datos con DataPrep

Limpieza de texto
Limpieza de fechas
Limpieza de IBANs
Duplicados
Limpieza de un DataFrame

Preparación de datos

Conversión de datos con Pandas

Cambiar la granularidad de una categoría
Convertir una categoría en dummies

Preparación de datos

Conversión de datos con scikit-learn

Cambiar la granularidad de una categoría
Convertir una categoría en dummies

Preparación de datos

Combinación con Pandas

Preparación de datos

Escalado con scikit-learn